

# Analyse prédictive et segmentation de la clientèle e-commerce

## Projet Olist

Segmentation de la clientèle

Analyse prédictive

Exploitation des données transactionnelles

Réalisé par :

**Darryl Momo**

**Demanou Levana**

**Laeticia Joyce Chuidjui**

Formation :

**Data / IA - Analyse sectorielle**

**Année : 2024-2025**

# Contexte & Enjeux Business

## ■ Contexte

- **Olist** : plateforme e-commerce B2C
- **Forte volumétrie** de données transactionnelles
- **Marché** très concurrentiel

## ■ Message clé

*Sans segmentation et analyse data, les décisions marketing sont génériques et peu rentables.*

## ■ Enjeux Business

- **Mieux connaître les clients**  
Comprendre les comportements d'achat et les préférences
- **Identifier des segments à forte valeur**  
Distinguer des profils clients qui apportent la plus grande valeur
- **Optimiser les actions marketing et commerciales**  
Cibler efficacement les bonnes personnes avec les bons messages

# Objectifs du Projet

Notre projet vise à exploiter les données e-commerce d'Olist afin d'obtenir des insights clients exploitables pour la prise de décision stratégique.



## Comprendre les comportements clients

Analyser les patterns d'achat, préférences et tendances pour mieux anticiper les besoins



## Segmenter la clientèle

Créer des segments data-driven pour ciblage personnalisé et optimisation des actions marketing



## Relier les segments à des indicateurs métier

Connecter les segments à des métriques business pour mesurer l'impact stratégique



## Préparer le socle pour des modèles prédictifs

Structurer les données et les insights pour des applications futures d'analyse prédictive



## Message clé


*L'objectif n'est pas juste de faire du clustering, mais de produire des segments compréhensibles et actionnables par les équipes business.*

# Données Utilisées

## Sources de données Olist

- Clients**  
Informations sur les clients
- Commandes**  
Informations sur les commandes livrées
- Articles commandés**  
Détails des articles dans chaque commande
- Paiements**  
Informations sur les modes et statuts de paiement
- Avis clients**  
Notes et commentaires des clients
- Produits**  
Informations sur les produits vendus

## Volumétrie des données



### Message clé

Nous travaillons sur des données réelles, complexes et représentatives d'un e-commerce à grande échelle.

# Architecture du Projet

## ■ Organisation professionnelle



### **data/raw**

données brutes



### **data/interim**

données nettoyées



### **notebooks**

pipeline analytique structuré séparation claire des étapes

## ■ Approche



Reproductible



Modulaire



Orientée métier

## ■ Message clé

Cette structure est proche des standards utilisés en entreprise data.

# Nettoyage & Qualité des Données

## Processus de Nettoyage



### Suppression des doublons

Identification et removal des enregistrements dupliqués pour garantir la qualité des données



### Gestion des valeurs manquantes

Analyse et traitement des champs vides ou null pour compléter les informations essentielles



### Filtrage des commandes livrées

Restriction aux commandes ayant atteint leur statut "livrée" pour analyser uniquement les transactions complètes



### Vérification des clés critiques

Validation de l'intégrité des clés primaires et étrangères pour garantir la cohérence des relations



### Résultat



**Données fiables** pour l'analyse



Aucun **biais majeur** introduit dans les résultats



Base de données **prête pour l'analyse** approfondie



### Message clé

Une segmentation n'a de valeur que si les données sont propres et cohérentes. Le nettoyage est la foundation de toute analyse data de qualité.

# Analyse Exploratoire (EDA)

## Observations clés



### Panier moyen très hétérogène

Les tailles de paniers varient fortement selon les clients et les commandes



### Majorité de clients à achat unique

La plupart des clients ne reviennent pas après leur première commande




### Distribution asymétrique des dépenses

Une petite partie des clients génère une grande partie des ventes



### Avis clients globalement positifs

Les commentaires laissés par les clients sont majoritairement favorables



### Message clé

L'EDA confirme la nécessité d'une segmentation pour distinguer des profils clients très différents.

# Construction des Features Clients

**Dimension finale :** 93 358 clients × 9 variables métiers

## Analyses RFM

### Recency

Temps écoulé depuis le dernier achat

### Frequency

Nombre de fois que le client a acheté

### Monetary

Somme totale dépensée par le client

## Variables Complémentaires

### Panier moyen

Valeur moyenne des commandes

### Nombre d'articles

Nombre total d'articles achetés

### Délai moyen de livraison

Temps moyen entre commande et livraison

### Note moyenne des avis

Note moyenne des produits achetés

### Nombre de catégories achetées

Nombre de catégories différentes achetées

# Standardisation des Variables

## Pourquoi scaler ?

- Variables sur des échelles différentes
- K-means sensible aux distances

## Méthode

### StandardScaler

Centrer réduire les variables pour obtenir une moyenne = 0 et écart-type = 1

## Message clé

*Le scaling garantit une segmentation équitable entre les variables.*

## Illustration de la standardisation

### Avant standardisation

Variable 1 (Panier)	Échelle: 0-1000
Variable 2 (Fréquence)	Échelle: 0-10
Variable 3 (Monetary)	Échelle: 0-5000

### Après standardisation

Variable 1 (Panier)	Échelle: -2 à +2
Variable 2 (Fréquence)	Échelle: -2 à +2
Variable 3 (Monetary)	Échelle: -2 à +2

*Les variables sont maintenant sur la même échelle, ce qui garantit une segmentation équitable.*

# Choix du Nombre de Clusters


## Méthode du coude (inertie)

- Recherche du "coude" dans la courbe d'inertie
- Point d'infexion où l'inertie diminue moins rapidement


## Score de silhouette

- Mesure la qualité de la séparation des clusters
- Score compris entre -1 et 1, plus proche de 1 = meilleur

## Méthode du coude



## Score de silhouette



## Résultat : k = 4 clusters retenus

Bon compromis lisibilité / performance

# Segmentation par K-Means

## Algorithme



### K-means

Algorithme de clustering non supervisé

- Minimise la variance intra-cluster
- Itérations jusqu'à convergence

## Résultat de la segmentation



~75%




~16%



~7%



<1%



## Résultats



### 4 segments clients distincts

Chaque cluster représente un profil client différent




### Répartition inégale mais réaliste

Reflects the natural distribution of customer value

## Message clé

Les segments reflètent la réalité business : tous les clients n'ont pas la même valeur.

# Profil des Clusters (Vue Globale)



## Légende

Cluster 0: Clients occasionnels

Cluster 1: Clients premium

Cluster 2: Clients réguliers

Cluster 3: Bons clients

### Message clé

Une petite partie des clients (Cluster 1) concentre une grande partie de la valeur.

### Profil global

- La majorité des clients (75%) sont des clients occasionnels
- Seulement 16% des clients sont des clients réguliers
- Seulement 7% des clients font partie du segment des "bons clients"
- Moins de 1% des clients sont des clients premium

# Interprétation Métier des Segments



## Clients occasionnels

- Panier moyen faible
- Achat unique
- Cœur de la base



## Clients réguliers

- Panier et dépenses modérés
- Bon potentiel de fidélisation



## Bons clients

- Dépenses élevées
- Avis clients positifs
- Sensibles à la qualité de service



## Clients premium

- Très forte valeur
- Très rares
- À traiter individuellement



## Message clé

Chaque segment appelle une stratégie marketing différente.

# Visualisation PCA


## Objectif

Vérifier la séparation des clusters obtenus après la segmentation par k-means. Le PCA permet de visualiser les données dans un espace réduit tout en préservant les relations de distance entre les points.

## Message clé

Le PCA confirme la cohérence de la segmentation. Les clusters sont bien séparés dans l'espace des composantes principales, ce qui valide la robustesse de notre approche de segmentation.

## Résultat



- **Bonne séparation globale** des clusters
- **Chevauchements limités** entre clusters
- Validité **statistique** de la segmentation

# Modélisation Supervisée (Appui à la Segmentation)

## Objectif

- Prédire l'appartenance à un segment
- Comprendre les variables discriminantes

## Modèle

- Algorithm** : Random Forest
- Validation** croisée

## Message clé

*Le modèle confirme la robustesse des segments.*

## Résultats

### Performance

**F1-score ≈ 0.996**



### Stabilité

- Modèle stable et robuste

## Validité des segments

- Les segments sont **discriminants** pour le modèle
- Les segments sont **homogènes** et **hétérogènes** entre eux

# Importance des Variables

## Variables les plus discriminantes



### Monetary

Dépenses totales des clients



### Panier moyen

Valeur moyenne des commandes



### Note moyenne des avis


Satisfaction client



### Délai de livraison

Temps d'attente moyen

## Importance relative des variables



### Message clé

La valeur client et l'expérience client (panier, notes, livraison) sont les facteurs clés de segmentation.

## **Pourquoi le modèle n'overfit pas (explication clé)**

## **Point fondamental**

**Les clusters ont été construits à partir des variables suivantes :**

## Recency Frequency

## Monetary Panier moyen

## Délai de livraison Note moyenne des avis

## Nombre de catégories

## Modèle supervisé

### Cluster 1 Cluster 2 Cluster 3 Cluster 4

La prédiction des clusters n'est pas un apprentissage prédictif, mais une dérivation logique des caractéristiques déjà utilisées pour la segmentation.

## **Interprétation correcte**

Le modèle n'a pas pour objectif de prédire un comportement futur.

Il apprend à reproduire la frontière de décision du clustering.



**Il s'agit d'un cas connu en data science : tautologie de segmentation**

# Objectif réel du modèle (vision entreprise)

## ■ Objectif du modèle supervisé

■ Pas prédire un comportement inconnu

■ Industrialiser la segmentation client

## ■ Utilité business

■ Assigner rapidement de nouveaux clients à un segment

■ Faciliter l'intégration CRM

■ Éviter de relancer un clustering complet

■ Outils marketing connectés

## Déploiement en entreprise

■ Segmentation

■ Modèle supervisé

■ Déploiement

## Pratique courante en entreprise

Cette approche est largement utilisée dans le monde des affaires pour automatiser et industrialiser les processus de segmentation tout en garantissant la cohérence des résultats.

■ Performance stable avec F1-score élevé  
(0.996 sur le jeu de test)